

Projet Big Data Écosystème:

Introduction:

Pour le choix du sujet, nous avons choisi d'étudier la partie architecture d'un système de musique en streaming.

Il existe évidemment des groupes connus mettant à notre disposition ce type de technologies Deezer, Spotify et Apple Musique pour ne citer que les plus populaires.

Notre objectif est donc de créer une architecture similaire en utilisant exclusivement les technologies vues en cours afin d'éviter de paraphraser une architecture existante.

L'avantage principal de la musique en streaming est l'accès d'un utilisateur à toutes les musiques stockées dans la base de données sans qu'elles ne soient stockées dans l'appareil de l'utilisateur. Cela permet d'ajouter les nouveautés sans interférer et déranger l'utilisateur.

L'utilisateur pouvant décider à tout moment de changer de musique, on doit pouvoir exécuter des requêtes le plus rapidement possible pour accéder à la bibliothèque musicale.

Puis l'utilisation de ce service crée lui-même des données sur l'utilisateur : Quel est son artiste préféré ? Quels sont les genres musicaux écoutés ? Est-ce que l'utilisateur s'intéresse aux nouveautés ? Toutes ses données peuvent être exploitées par la data science afin de créer des suggestions personnalisées pour l'utilisateur.

Puis ces données créent un profil utilisateur qui peut être comparé aux profils des autres utilisateurs. Combiné avec des techniques de data sciences et des algorithmes prédictifs, il est possible de proposer de manière plus précise des suggestions de nouveaux artistes.

LAFAY Baptiste
LANCMAN Nathan
ING5 BDA Gr2
Architecture :

1 - Nos Besoins:

Afin de pouvoir collecter les informations émises:

Comme nous l'avons évoqué, de nombreuses requêtes doivent pouvoir être effectuées. Les recherches doivent être le plus rapide possible.

2 - Notre solution

Traitement des messages:

Apache Kafka: est une application open source de traitement des flux de données et de mise en file d'attente des messages capable de traiter un grand nombre de données, provenant de diverses sources, et de les acheminer vers plusieurs consommateurs.

Avec Apache Hadoop:

Hadoop est un framework libre et open source écrit en Java destiné à faciliter la création d'applications distribuées. Basé sur le système Map/Réduire, il permet de segmenter, de stocker et de traiter de grande quantité de données. Le système Hadoop est adapté à notre projet car nous n'avons pas besoin de requêtes avancées.

Hadoop est déjà utilisé pour faire de la recommandation analytique pour les clients. Personnalisant ainsi les suggestions, on peut le retrouver ce modèle chez Netflix, Ebay ou Facebook.

YARN, *Yet Another Resource Negotiator*, est la fonctionnalité de Hadoop qui a permis de ne plus limiter ce dernier aux fonctions map Reduce. Il s'agit d'un gestionnaire de ressources centrale. Les clusters Hadoop sont maintenant en mesure de lancer des applications d'analyse en temps réel, de streaming data et requêtes interactives sur Apache Spark tout en laissant tourner MapReduce.

Il s'occupe d'accepter les requêtes d'un utilisateur et de les diriger vers les nœuds correspondants.

HDFS: est un système scalable basé sur le Java permettant de stocker des données sur de nombreuses machines sans organisation préalable. Il nous permettra de stocker nos données, notamment notre bibliothèque musicale. Avec une hiérarchie horizontale, nous évitons une saturation de nos ressources.

Apache Kafka: Kafka est une application open source de traitement des flux de données et de mise en file d'attente des messages capable de traiter jusqu'à plusieurs millions de messages par seconde, provenant de différentes sources, et de les conduire vers leurs destinations.

Analyse de résultat:

Les données récoltées par Hadoop sont envoyées au logiciel Microsoft Power BI permettant de facilement visualiser les résultats obtenus. L'objectif dans l'analyse est de pouvoir mieux allouer les ressources. Exemple: si 90% des utilisateurs écoutent du Classique, et que 20% écoutent du Reggae alors les nœuds traitant des données comportant du classique ont besoin de plus de ressources que ceux qui traitent du Reggae.

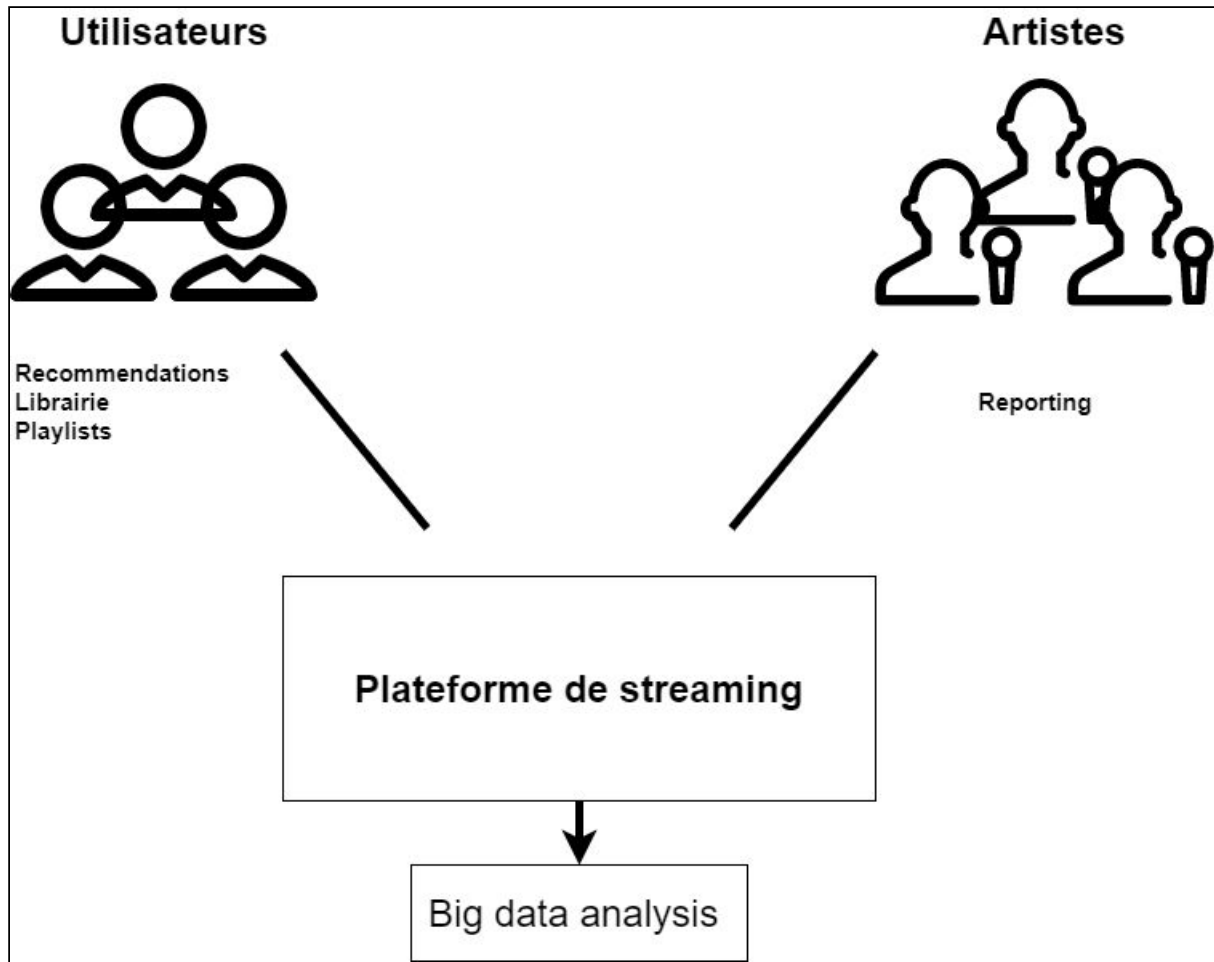
Et grâce au système YARN, nous pouvons redistribuer à tout moment les ressources.

Description détaillée du use case

Dans un service de streaming de musique il y a beaucoup de manipulation de données qui se passe sans que l'utilisateur s'en rende compte. Comment la plateforme arrive-t-elle à stocker des millions de morceaux, à faire des recommandations musicales personnalisées à chacun de ses utilisateurs, à créer des listes de musique populaires en temps réel, enregistrer les playlists de chaque utilisateur etc. Nous allons présenter une architecture d'une plateforme de streaming musicale simplifiée qui expliquera la big data derrière un tel projet.

Admettons que nous voulons que notre service puisse analyser les tendances, les performances de chaque artiste pour ensuite les rapporter à leurs labels discographiques respectifs. Quels outils de systèmes distribués pourrions-nous utiliser afin de mettre en place ce type d'infrastructure?

On peut représenter un schéma ultra-simplifié de la relation entre les utilisateurs, les artistes et la plateforme :



Présentation des technologies impliquées

Pour cette architecture nous allons utiliser les frameworks et outils suivants :

- La plateforme Hadoop
- HDFS comme système de stockage distribué pour tout type de données
- YARN en tant que ressource manager et passerelle entre HDFS et MapReduce/Spark
- MapReduce & Apache Spark pour du big data processing
- Kafka pour le messaging et stream processing

Apache Hadoop

Hadoop est un framework libre et open source écrit en Java destiné à faciliter la création d'applications distribuées. Basé sur le système Map/Réduire, il permet de segmenter, de stocker et de traiter de grande quantité de données. Le système Hadoop est adapté à notre projet car nous n'avons pas besoin de requêtes avancées.

LAFAY Baptiste
LANCMAN Nathan
ING5 BDA Gr2

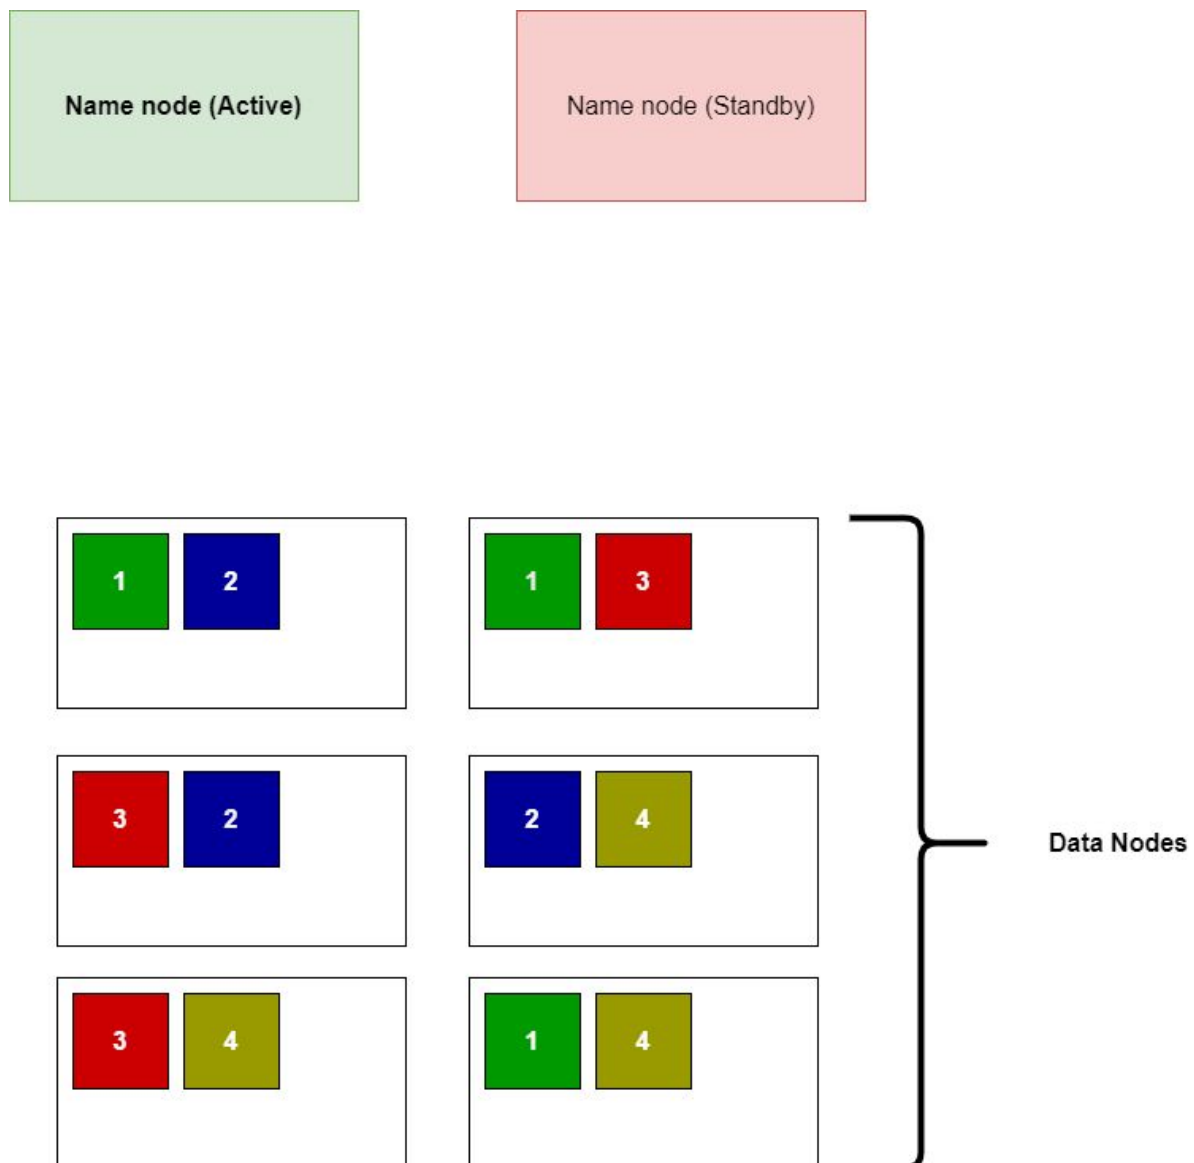
Hadoop est déjà utilisé pour faire de la recommandation analytique pour les clients. Personnalisant ainsi les suggestions, on peut le retrouver ce modèle chez Netflix, Ebay ou Facebook.

Hadoop Distributed File System (HDFS)

HDFS est un système scalable basé sur le Java permettant de stocker des données sur de nombreuses machines sans organisation préalable. Il nous permettra de stocker nos données, notamment notre bibliothèque musicale. Avec une hiérarchie horizontale, nous évitons une saturation de nos ressources.

HDFS se base sur un système master / esclave composé de clusters et de nodes.

Voici un schéma simplifié de l'architecture d'un cluster dans HDFS :



LAFAY Baptiste
LANCMAN Nathan
ING5 BDA Gr2

Chaque cluster d'une architecture HDFS possède 2 ou plus namenodes. L'une est active tandis que les autres sont en standby. C'est le namenode actif qui s'occupera des opérations du cluster, et le / les standby sont présents au cas où le namenode actif tomberait en panne. Le namenode assure la répartition de blocs de données (représenté par des petits blocs de couleurs numérotés dans les data nodes) dans les datanodes.

Un bloc est une partie d'un fichier de taille 128mb qui est dupliqué sur plusieurs datanodes afin d'assurer la disponibilité de ces données.

Les namenodes sont "conscients" des changements effectués dans le cluster car ils partagent des métadonnées.

Pourquoi avons nous choisi HDFS

HDFS est idéal pour stocker des données massives. Le système de répartition des données en blocs dans des nodes nous garantit de ne pas avoir de période d'indisponibilité des fichiers si l'une de nos data node est en panne car ces données auront été dupliquées. HDFS permet aussi une extensibilité très facile, grâce à la hiérarchie horizontale, ce qui nous permet de rajouter du matériel informatique à la suite des autres sans avoir à remplacer les anciens.

Yet Another Resource Negotiator (YARN)

YARN est la fonctionnalité de Hadoop qui a permis de ne plus limiter ce dernier aux fonctions map Reduce. Il s'agit d'un gestionnaire de ressources centrale. Les clusters Hadoop sont maintenant en mesure de lancer des applications d'analyse en temps réel, de streaming data et requêtes interactives sur Apache Spark tout en laissant tourner MapReduce.

Il s'occupe d'accepter les requêtes d'un utilisateur et de les diriger vers les nœuds correspondants.

YARN est composé d'un ressource manager par cluster ainsi que d'un node manager par datanode. Tout comme pour le namenode HDFS, il existe dans un cluster un ressource manager actif ainsi qu'un ou plusieurs en standby.

Chaque node manager est responsable du contrôle d'un conteneur. Un conteneur s'occupe d'allouer des ressources (processeur, mémoire vive, etc.) à un processus / job.

Voici un schéma simplifié de l'architecture YARN :

Pourquoi avons nous choisi YARN

YARN est un middleware entre HDFS et MapReduce permettant de gérer les ressources d'un cluster.

LAFAY Baptiste

LANCMAN Nathan

ING5 BDA Gr2

YARN fournit un API REST nous permettant de travailler avec d'autres outils Hadoop, notamment Spark.

Apache Kafka

Apache Kafka: Kafka est une application open source de traitement des flux de données et de mise en file d'attente des messages capable de traiter jusqu'à plusieurs millions de messages par seconde, provenant de différentes sources, et de les conduire vers leurs destinations.